

職務経歴書

2026 年 1 月 12 日現在 山口 敏弘

職務要約

データサイエンティストおよび機械学習エンジニアとして 10 年のキャリアを持ち、メディア、エンタープライズ SaaS、インフラ、広告など多岐にわたる業界で事業課題を技術で解決してきました。特に推薦システム、MLOps、そして最新の LLM/マルチエージェント開発において、設計から実装・評価まで End-to-End で主導した実績を豊富に有しています。

直近ではフリーランスとして、マルチエージェント技術を活用したエンタープライズ向け AI プラットフォーム開発に従事しています。LangGraph を用いた複雑なワークフローのオーケストレーションや、100 種類以上のツールを動的に呼び出すエージェント基盤の構築、LiteLLM によるマルチプロバイダー統合など、スケーラビリティとコスト・レイテンシ最適化を両立する LLM アプリケーション開発を強みとしています。

推薦システムで培った Embedding 技術やベクトル検索の知見と、最新の RAG (Corrective RAG/Self-RAG) や DSPy によるプロンプト最適化手法を組み合わせ、単なるチャット UI に留まらない「実務で機能する自律型 AI システム」の構築を通じて、ビジネス価値の最大化に貢献します。

活かせる経験・知識・技術

得意分野

- **LLM/マルチエージェント開発:** LangChain/LangGraph を用いたオーケストレーション、自律型エージェントの設計、Tool-use 最適化
- **推薦システム・埋め込み技術:** Two-Tower Architecture、メトリックラーニング、ベクトルデータベース構築
- **RAG・評価設計:** Ragas/LangFuse を用いた検索精度・回答品質の定量的評価、ハルシネーション抑制

- **MLOps/基盤構築:** Vertex AI Pipelines や Databricks を用いた学習・推論パイプラインの自動化
- **フルスタック開発:** Next.js (TypeScript) から Python/Go によるバックエンド、AWS/GCP のインフラ構築まで

技術スタック

- **LLM/AI:** LangChain, LangGraph, CrewAI, Amazon Bedrock, LiteLLM, Dify, Ragas, LangFuse, DSPy
- **ML/DL:** Python, PyTorch, TensorFlow, scikit-learn, Pandas, PySpark, XGBoost
- **Backend:** Python (FastAPI, Flask), Go, Node.js (NestJS), Prisma, tRPC
- **Frontend:** TypeScript, Next.js, React, Tailwind CSS
- **Infrastructure/Data:** AWS, GCP, Azure, Databricks, BigQuery, Pinecone, Weaviate, Terraform, Docker, Kubernetes

資格

- ネットワークスペシャリスト
- 情報セキュリティ安全確保支援士試験合格

活動・登壇

- **MLOps 勉強会登壇:** 「推薦システムにおける継続的学習パイプラインの実装」
- **Databricks 公式イベント登壇:** 「Spark を用いた大規模データ処理の最適化」

プロダクト開発/サービス公開

shisapost (<https://www.shisapost.com/>)

- **期間:** 2024 年 10 月～現在（継続運用中）
- **概要:** LLM を活用したパーソナライズ型ニュースキュレーションサービス。数千の

ソースからユーザーの関心に合致する情報を抽出し、要約・影響分析・示唆を自動生成。

- **技術的特徴:**

- **マルチエージェント構成:** ニュース収集、重要度判定、要約、パーソナライズの各工程を独立したエージェント（LangGraph）が担当。
- **高度な RAG 実装:** Corrective RAG を導入し、外部検索エンジンと連携することで情報の鮮度と正確性を担保。
- **パーソナライゼーション:** 過去の閲覧履歴をベクトル化し、ユーザーごとに最適な重み付けで情報を配信。

- **成果:**

- 商用運用開始後、月額課金ユーザーを獲得。
 - 配信メールの開封率 50% 以上を維持し、パーソナライズの有効性を実証。
 - インフラコストを 1 ユーザーあたり月間数円単位まで最適化。
-

ポートフォリオ

- **Agentic-Workflow-Patterns**

- LangGraph を用いた「反省（Reflection）」「計画（Planning）」パターンの実装サンプル集。

- **Multi-LLM-Gateway-Sample**

- LiteLLM を活用した、モデルのフォールバック、キャッシュ、コストモニタリング機能を備えた API ゲートウェイの実装。
-

職務経歴詳細

2024 年 01 月~現在: フリーランス

- **エンタープライズ向け AI プラットフォーム開発（大手 SaaS 企業）**

- 期間: 2024/01 - 現在

- **概要:** 100 以上の業務ツールと連携し、複雑なワークフローを自動化する AI エージェント基盤の開発。
- **担当:** リード AI エンジニア
- **環境:** Next.js, NestJS, Python (FastAPI, LiteLLM), LangGraph, GCP (Cloud Run, BigQuery), Terraform
- **詳細:**
 - * **オーケストレーション最適化:** LangGraph を導入し、従来の一方向的なチェーンでは困難だった「ループ」や「条件分岐」を含む複雑な業務プロセスを安定的に自動化。
 - * **スケーラブルなツール管理:** 100 種類以上の API ツールを動的に選択・実行するための Tool Registry を構築。Pydantic を用いた厳格なスキーマ管理により、LLM のツール呼び出しエラー率を 15% 低減。
 - * **コスト・レイテンシ対策:** LiteLLM によるモデルルーティングを実装。プロンプトの複雑度に応じて GPT-4o と Claude 3.5 Sonnet を使い分け、精度を維持しつつトークンコストを 30% 削減。
 - * **SPEC 駆動開発の導入:** 大規模チームでの開発において、OpenAPI/Type-Spec を用いた仕様先行開発を徹底し、フロントエンド・バックエンド間の手戻りを最小化。
- **Unity + 生成 AI 連携ゲーム開発プロジェクト**
 - **期間:** 2024/10 - 2025/03
 - **概要:** LLM を用いた NPC の動的思考エンジンおよび生成 AI によるアセット制作パイプラインの構築。
 - **詳細:** ML-Agents を用いた強化学習と LLM による意思決定を統合。3D モデル生成 AI (Tripo3D 等) の API 連携により、アセット制作工数を 50% 削減。

2023 年 07 月~2023/12: 業務委託

- **社内ナレッジ活用 RAG 導入プロジェクト PoC**
 - **期間:** 2023/07 - 2023/12
 - **概要:** 膨大な社内ドキュメント (PDF/Wiki) から高精度に回答を生成するシステムの構築。

- 担当: PM 兼 リードエンジニア
- 環境: Amazon Bedrock (Claude 3), LangChain, LangFuse, Pinecone
- 詳細:
 - * **精度の定量的改善:** Ragas を用いた評価基盤を構築。チャンクサイズの最適化とハイブリッド検索（ベクトル＋キーワード）の導入により、初期回答精度（Faithfulness）を 65% から 92% へ向上。
 - * **ビジネスインパクト:** 導入部署において、情報検索に要する時間を月間平均 30 時間/人削減。
 - * **ハルシネーション対策:** 引用元の明示および、メタデータを用いたフィルタリングにより、回答の信頼性を担保。

2022 年 01 月~2023/06: HJ ホールディングス株式会社

• TVOD サービスの推薦システム構築 (2024 年)

- 担当: データサイエンティスト / 機械学習エンジニア / リード
- 環境: Python, PyTorch (PyTorch Lightning / PyTorch Similarity), Vertex AI (Pipelines / Experiments / Workbench), BigQuery, Dataflow, Digdag, GitLab CI/CD, Two-Tower Architecture, Metric Learning (Triplet Loss)
- 概要:
 - * HJ ホールディングス株式会社が運営する VOD サービスにおいて、TVOD（都度課金型ビデオ・オン・デマンド）作品の視聴促進を目的とした推薦システムを構築。
 - * ユーザーの嗜好に合わせたパーソナライズ、および関連性の高いアイテム推薦により、コンバージョン（購入率）向上とユーザー体験の改善を実現。5 名体制のチームで、設計から本番運用までを一貫して担当。
- 課題:
 1. **推薦精度の高度化:** 従来のアルゴリズムでは捉えきれないアイテム間の潜在的類似性や、ユーザーの文脈（セッション内行動）の反映。
 2. **コールドスタート問題の解消:** 新規作品や視聴履歴の少ないユーザーへの対応。
 3. **MLOps 基盤の確立:** 学習・推論・評価の自動化パイプラインの欠如。

4. **定性的な妥当性:** ジャンル間の自然な遷移など、違和感のない推薦結果の提供。

– **取り組み (Action):**

- * **Two-Tower Architecture による埋め込み構築:** BERT 等の事前学習済みモデルを活用し、アイテムのメタデータと視聴ログを統合した Two-Tower モデルを設計。スケーラブルな近傍探索を実現するベクトル表現を構築。
- * **メトリックラーニング (Triplet Loss) の導入:** PyTorch Similarity を用い、同一セッション内での連続視聴パターンからポジティブペアを抽出。Lift 値を教師ラベルとして活用し、関連性の高いアイテムがベクトル空間上で近くなるよう最適化。
- * **ジャンル概念を考慮した学習設計:** 親ジャンル概念を導入し、特定のジャンルに偏りすぎず、かつ関連性の高いジャンル間を自然に推薦できるよう損失関数を調整。
- * **Vertex AI Pipelines を用いた MLOps の実装:** BigQuery からのデータ抽出、Dataflow 前処理、Vertex AI 上での学習・評価・推論をパイプライン化。GitLab CI/CD と連携し、モデル更新を完全自動化。
- * **評価・可視化プロセスの確立:** UMAP を用いて埋め込み空間を可視化し、学習状況を定性的に検証。A/B テストを設計し、主要 KPI への影響を統計的に評価する体制を構築。

– **成果 (Result):**

- * **精度の向上:** アイテム埋め込みの評価指標 (Accuracy) において、**0.91 から 0.96 への改善**を達成。
- * **定性的な改善:** UMAP 分析により、ジャンル間の類似性が適切に学習され、ユーザーにとって違和感のない「自然な関連作品」の提示が可能に。
- * **運用負荷の軽減:** Vertex AI Pipelines と Digdag による定期実行ジョブ構築により、モデル再学習・推論デプロイの手動運用工数を大幅に削減。
- * **ビジネスインパクト:** A/B テストにて、従来手法と比較して CTR および視聴時間 (Completion Rate) の向上を確認。

2021 年 12 月~2022 年 03 月: EY ストラテジー・アンド・コンサルティング株式会社

- データ駆動型事業改善コンサルティング

- 担当: データサイエンティスト / データアナリスト
- 環境: Python, Elasticsearch, Kibana, Pandas, scikit-learn
- 概要: 大手クライアントのビジネス課題に対し、膨大なデータの統計分析と可視化を通じて解決策を提示。
- 詳細:
 - * 大規模ログデータのリアルタイム分析: Elasticsearch/Kibana を活用し、非構造化ログデータから KPI に直結するインサイトを抽出するダッシュボードを構築。
 - * 統計的因果推論による施策評価: 単なる集計に留まらず、scikit-learn 等を用いた因果推論を行い、施策のビジネスインパクトを定量化。
 - * 意思決定支援: 分析結果を経営層向けに可視化し、データに基づく迅速な意思決定プロセスを確立。

2021 年 06 月~2021/12: 株式会社 JMDC

- 医療データ利活用プラットフォームの開発

- 担当: バックエンドエンジニア
- 環境: AWS (Step Functions, Lambda, KMS), Python, Terraform
- 概要: 保険審査業務の自動化および製薬向け分析レポート基盤の構築。
- 実績:
 - * データパイプライン構築: AWS Step Functions を用いたサーバーレス処理により、医療情報の照合作業リードタイムを数日から数時間へ短縮。
 - * セキュリティ実装: AWS KMS を用いた厳格な暗号化設計により、機密性の高い医療データの安全な取り扱いを実現。

2019 年 08 月~2021 年 05 月: 株式会社日本経済新聞社（嘱託契約）

- ニュースアプリのパーソナライズ基盤開発および MLOps 推進

- 担当: データ基盤エンジニア / データサイエンティスト

- 環境: Databricks, Spark (PySpark/Scala), Python, AWS, GCP, MLFlow, BERT, Golang
- 詳細:
 - * **大規模データ基盤の統合:** Databricks (Spark) を導入し、数百万ユーザーのアクセスログを処理するスケーラブルなデータ基盤を構築。
 - * **ハイブリッド推薦アルゴリズムの開発:** 従来の協調フィルタリングに加え、BERT を用いた記事のセマンティック（意味）分析を導入。ユーザーの閲覧文脈（Context）を考慮した高精度な推薦を実現し、CTR を大幅に改善。
 - * **MLOps の確立:** MLFlow 活用による実験管理とデプロイパイプラインの自動化を行い、モデル改善サイクルを数日単位から数時間単位へ短縮。
 - * **高負荷対策:** Golang を用いた高パフォーマンスなデータ処理コンポーネントを実装し、スパイクアクセス時でも安定した推薦レスポンスを維持。

2017 年 04 月~2019 年 01 月: 株式会社グリッド

・ 自社 DL フレームワーク (ReNom) 開発およびプラント制御の強化学習プロジェクト

- 担当: 機械学習エンジニア / データエンジニア
- 環境: Python, Flask, Vue.js, MQTT, VGG, VAE, SSG, 強化学習
- 概要: 自社開発ディープラーニングフレームワーク (ReNom) の機能拡張、および産業用プラントの最適化を目指した強化学習プロジェクトの基盤構築に従事。
- 詳細:
 - * **SOTA アルゴリズムの実装:** VGG, VAE, SSG（半教師あり学習）などの最新アルゴリズムを論文から実装し、ライブラリのモジュールとして製品化。
 - * **リアルタイム強化学習基盤:** プラント制御のため、MQTT を用いた高頻度 IoT データ収集パイプラインを設計・構築。
 - * **可視化ダッシュボード:** Flask/Vue.js を用いて、学習状態や制御シミュレーションの結果をリアルタイムに可視化する環境を整備。
 - * **成果:** 自社ライブラリの機能拡充により外観検査案件への対応力を強化し、物理プラント制御における AI 適用の実証に成功。

2016 年 01 月~2017 年 03 月: 株式会社 Cuon

- **スタートアップ向け Web サービス開発**

- 担当: Web エンジニア
- 環境: Ruby on Rails, PHP, MySQL, AWS, JavaScript
- 概要: 受託開発における Web アプリケーション設計・実装。
- 詳細:
 - * **フルスタック開発:** アジャイル開発チームにおいて、Rails を用いたバックエンド実装からフロントエンド連携までを一貫して担当。
 - * **サービス立ち上げ:** スタートアップ企業の MVP (Minimum Viable Product) 開発に携わり、高速なイテレーション開発の実践経験を積む。

2014 年 05 月~2015 年 12 月: 株式会社 AP コミュニケーションズ

- **大規模インフラ運用・保守および自動化**

- 担当: インフラエンジニア
- 環境: Windows Server, Linux, PowerShell, VMware, JP1
- 概要: 企業の基幹システムのサーバー運用・保守および監視業務。
- 詳細:
 - * **安定稼働の維持:** 24/365 体制のシステム監視および障害対応を行い、高可用性が求められるシステムの SLA 遵守に貢献。
 - * **運用自動化:** PowerShell 等を用いた定型作業のスク립ト化を推進し、オペレーションミス削減と工数短縮を実現。

- **日本通信株式会社 (2013/04-2014/04):** LAMP 構成によるサービスサイトの設計・構築を担当。エンジニアとしてのキャリアを開始。